Glimmerfen

Diseño generativo de personajes con GAN

Proyecto 2 — Deep Learning 2026 — Universidad del Valle

Cindy Gualim · Gadiel Ocaña

Docente: Kevin Recinos

Universo y datos: Glimmerfen

- Espíritus guardianes elementales de un bosque brumoso: cuerpo tipo blob, ojos grandes, apéndice opcional (cuernos, alas, orejas, cola, antena).
- Seis elementos (fuego, agua, tierra, aire, luz, sombra), cada uno con su paleta de color.
- Dataset: 4000 imágenes de 64x64, generadas por código propio (PIL) — sin descargas de internet, sin rostros reales ni personajes de terceros. Licencia: CC0 / del equipo.
- Preparación: normalización a [-1,1]; aumento de datos por flip horizontal.

Arquitectura de la GAN

- DCGAN (Radford et al., 2015): Generador con 5 ConvTranspose2d + BatchNorm + ReLU, salida Tanh.
- Discriminador con 4 Conv2d + LeakyReLU, normalización intercambiable (BatchNorm / Normalización Espectral / ninguna).
- Se eligió DCGAN por ser la arquitectura recomendada para empezar simple y por su comportamiento bien documentado en 64x64.
- Mismo Generador en las 3 corridas; la variable que cambia es siempre el Discriminador y/o la función de pérdida.

Experimento de pérdida: BCE vs. WGAN-GP

Hipótesis: WGAN-GP mejora la estabilidad al evitar la saturación de la divergencia JS

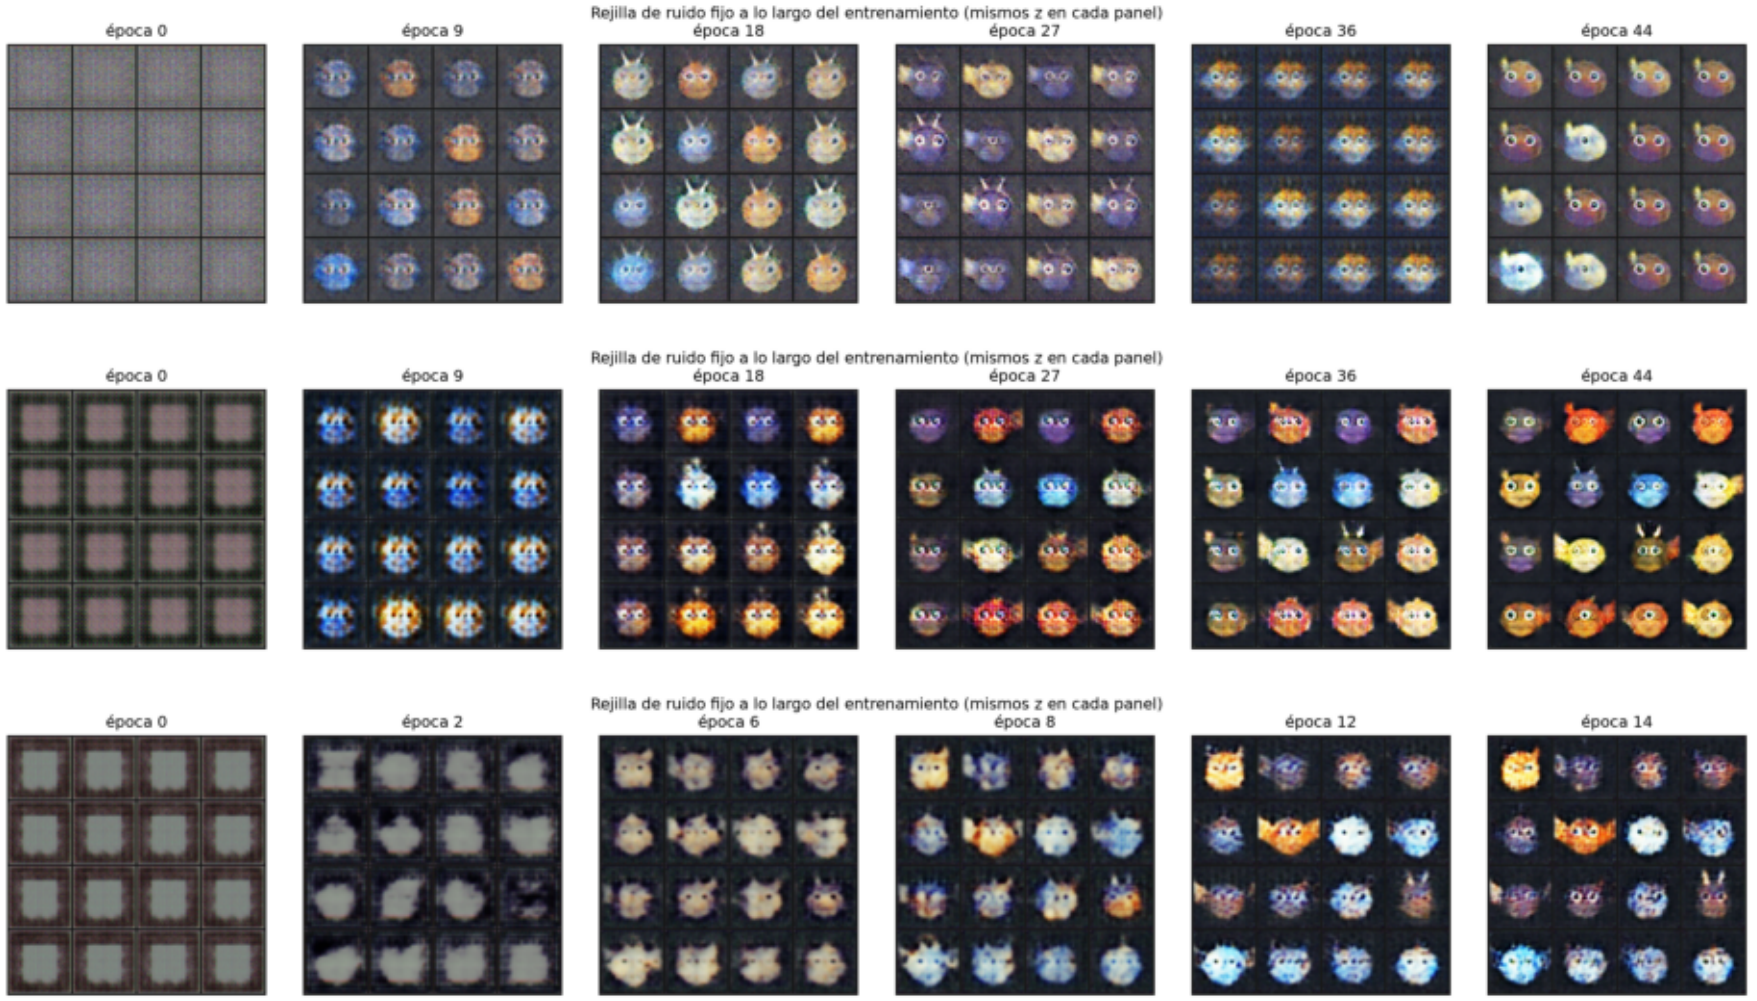
- Configuración controlada: mismos datos, semilla y ruido fijo de evaluación.
- Cambio de literatura (no arbitrario): crítico sin BatchNorm + Adam(1e-4,(0,0.9)) + n_critic=5/3, tal como exige Gulrajani et al. (2017).
- LIMITACIÓN DECLARADA: por falta de memoria del equipo, esta corrida se redujo a 15 épocas (no 45) y feature_maps=32 (no 64) para poder completarse — no es comparación justa de calidad final.
- Resultado: la pérdida del crítico decrece monótona y suave (de -90 a -14), sin los picos bruscos de BCE — confirma la dinámica más predecible esperada, aunque sin converger del todo.

Experimento de estabilización: BatchNorm vs. Normalización Espectral

Hipótesis: la normalización espectral acota la Lipschitz de D y evita que domine a G

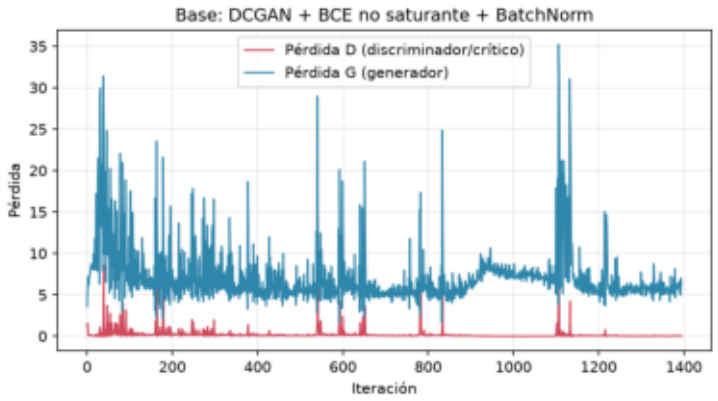
- Configuración controlada: mismos datos, semilla, 45 épocas, ruido fijo y misma pérdida (BCE).
- Única variable que cambia: normalización del discriminador.
- Resultado: pérdida D media 0.076 (base, cerca de 0 = alarma) vs. 0.730 (espectral); varianza de G 3.34 vs. 0.53 — hipótesis confirmada, se eligió este modelo para la galería.

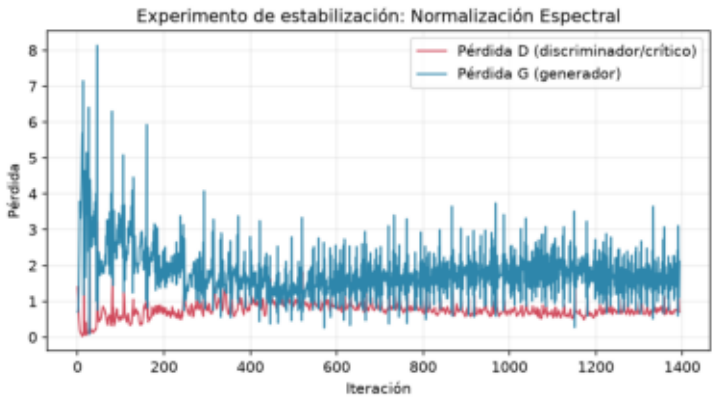
Evidencia 1: rejilla de ruido fijo

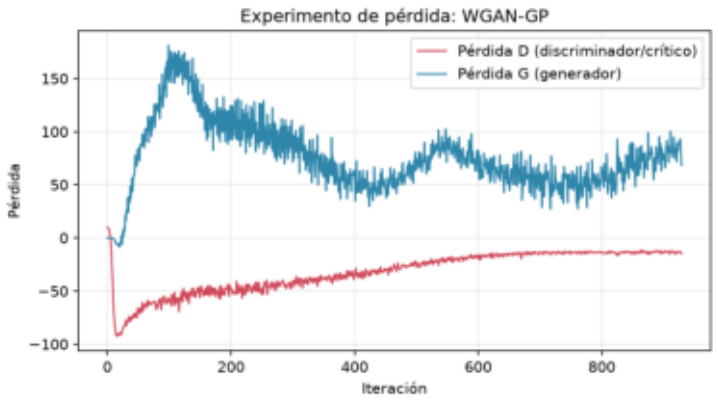


Mismo lote de 16 z en cada panel, a lo largo del entrenamiento (baseline, normalización espectral, WGAN-GP).

Evidencia 2: curvas de pérdida interpretadas







Evidencia 3: vecinos más cercanos

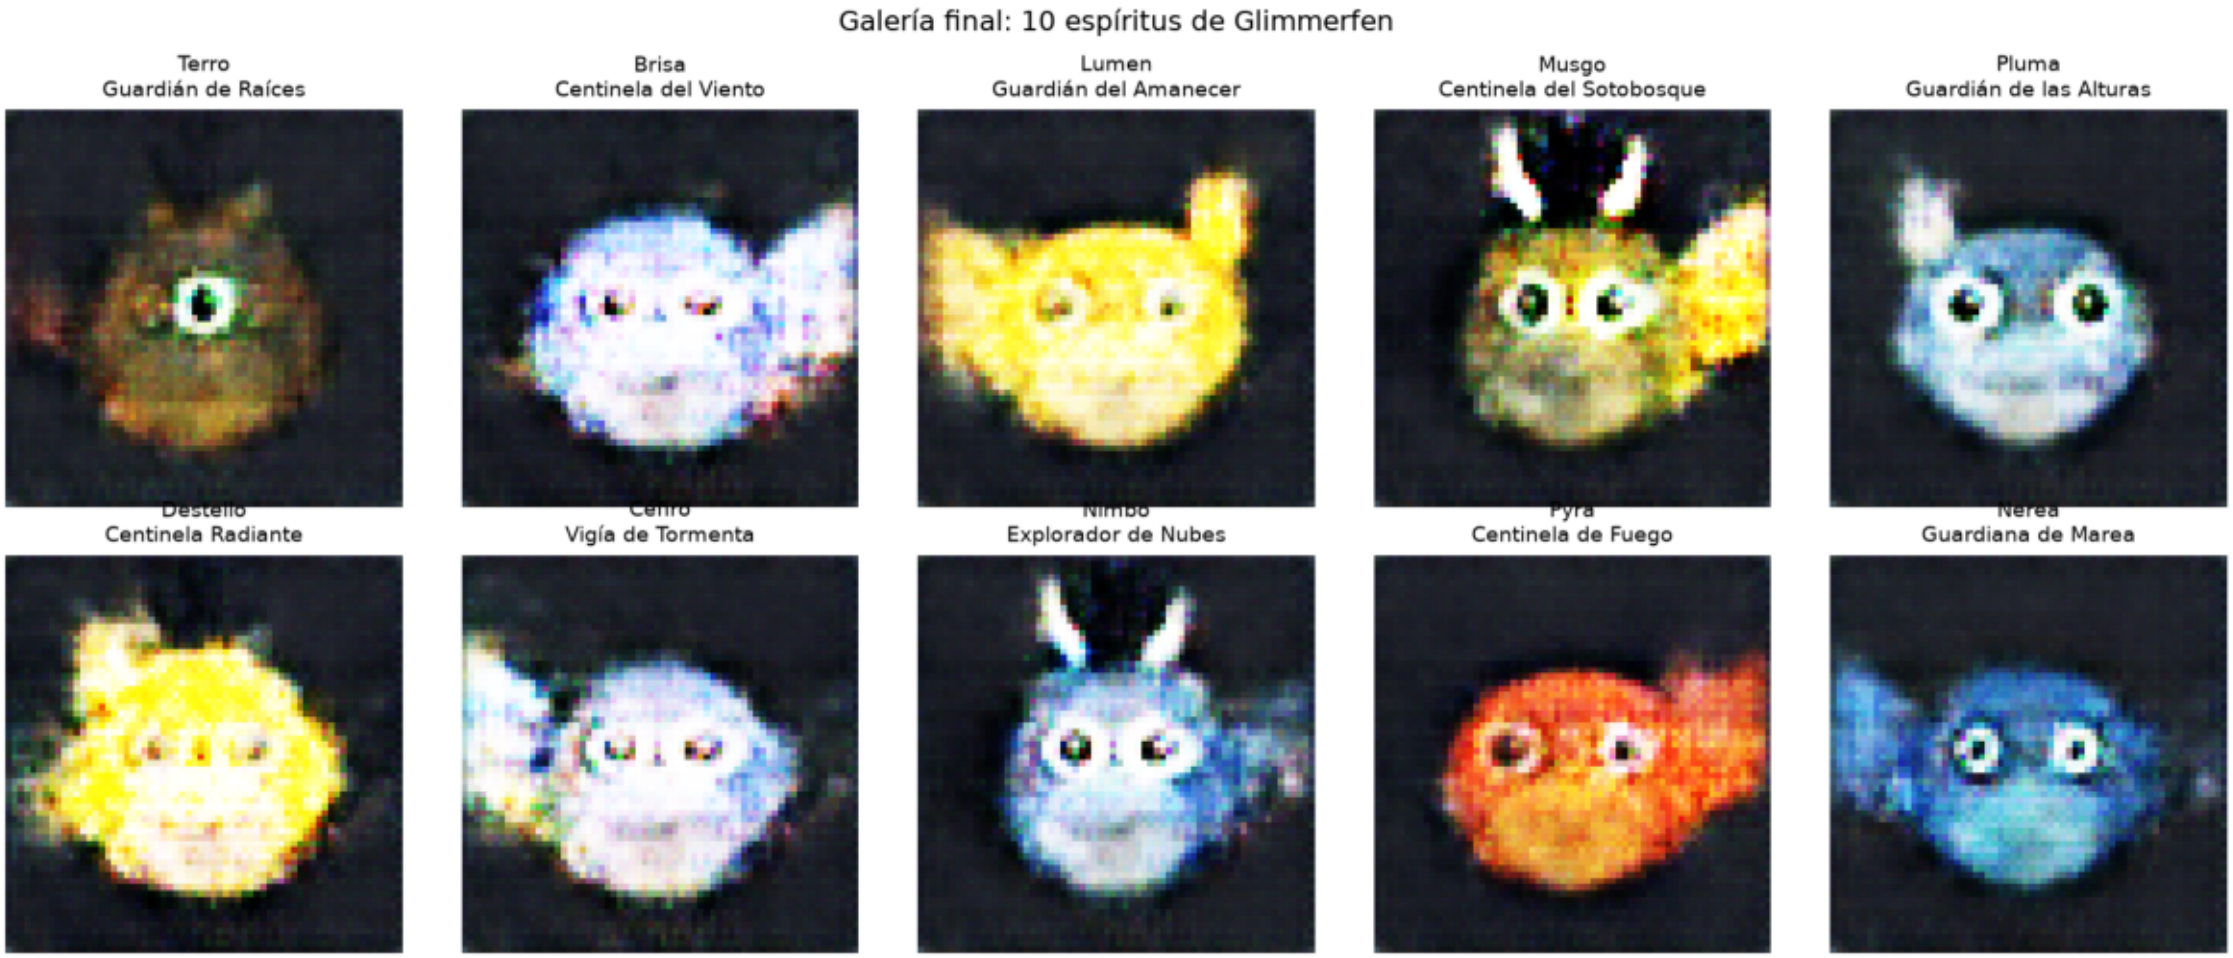


Fila superior: personaje generado. Fila inferior: vecino más cercano en el set de entrenamiento (MSE de píxeles).

Problemas encontrados y decisiones tomadas

- D domina a G en la base (pérdida de D ≈0 sostenida) -> colapso de modos parcial visible en la rejilla de ruido fijo entre las épocas 27 y 44. Motivó el experimento de estabilización.
- Restricción real de cómputo: WGAN-GP se interrumpió varias veces por falta de memoria del equipo; se resolvió reduciendo su presupuesto (feature_maps=32, n_critic=3, 15 épocas).
- Bug encontrado y corregido: train() no limpiaba snapshots/ entre reintentos, mezclando imágenes de configuraciones distintas bajo el mismo experimento — corregido en el código.
- Primera versión de la selección de galería daba 8/10 personajes casi idénticos (prohibido por el enunciado); se corrigió con un algoritmo farthest-point que maximiza diversidad real.

Galería final: 10 espíritus de Glimmerfen



Tasa de selección declarada: 10 de 300.

Conclusiones, limitaciones y reflexión final

- Normalización espectral cumplió su hipótesis con evidencia cuantitativa clara; WGAN-GP mostró la dinámica esperada pero no se pudo comparar en igualdad de condiciones (limitación de cómputo).
- El universo es deliberadamente simple (generado por código) para poder documentar origen/licencia con certeza y entrenar algo real en el tiempo disponible — un dataset de arte a mano daría más detalle pero sacrificaría esa trazabilidad.
- Reflexión: Terro es el personaje más difícil de defender como 'nuevo' (vecino más cercano a solo MSE=616, 2.5-7x más cerca que el resto). Esto sugiere que el modelo aprendió las categorías del universo (paleta, apéndice, N° de ojos) y las recombina, en vez de memorizar — pero las combinaciones más comunes en el dataset quedan, por definición, más cerca de algún ejemplar real.

Matriz de evidencias

Evidencia	Diapositiva	Conclusión	Limitación
Rejilla de ruido fijo	6	Base colapsa parcial; espectral mantiene 16 identidades distintas	WGAN-GP (15 épocas) no comparable en diversidad
Curvas de pérdida	7	D≈0 en base (alarma); espectral estable (~0.73, 6x menos var. en G)	Umbrales de "sano" son cualitativos
Vecinos más cercanos	8	Ningún personaje casi idéntico (todos MSE>600, umbral=60)	Solo compara contra nuestro propio dataset
Galería final (10 personajes)	10	10 personajes diversos (5/6 elementos, 1-2 ojos, apéndices variados)	Puntaje viene del propio discriminador, no de humanos